

Universidad de Costa Rica

Facultad de Ingeniería

Escuela de Ingeniería Eléctrica

IE-0499 – Proyecto Eléctrico

I ciclo 2026

Bitácora de Proyecto: Diseño e Implementación de un  
Protocolo Reproducible de Evaluación de Similitud de Voz  
para Sistemas TTS y Voice Conversion.

Daniel Valverde Ortiz - C28041

Grupo 001

Profesor: Jaime Cascante Vindas

# Índice

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>Introducción y Resumen del Proyecto</b>                   | <b>4</b>  |
| <b>1. Semana 1: 9 al 15 de marzo</b>                         | <b>5</b>  |
| 1.1. Lunes 9 y Miércoles 11 . . . . .                        | 5         |
| <b>2. Semana 2 (16 al 22 de marzo)</b>                       | <b>6</b>  |
| 2.1. Miércoles 18 de marzo . . . . .                         | 6         |
| 2.2. Viernes 20 de marzo . . . . .                           | 7         |
| <b>3. Semana 3 (23 al 29 de marzo)</b>                       | <b>8</b>  |
| 3.1. Miércoles 25 de marzo . . . . .                         | 8         |
| 3.2. Viernes 27 de marzo . . . . .                           | 9         |
| <b>4. Semana 4 (30 de marzo a 5 de abril) - Semana Santa</b> | <b>10</b> |
| 4.1. viernes 3 de abril . . . . .                            | 10        |
| <b>5. Semana 5 (6 al 12 de abril)</b>                        | <b>11</b> |
| 5.1. Miércoles 8 de abril . . . . .                          | 11        |
| 5.2. Viernes 10 de abril . . . . .                           | 12        |
| <b>6. Semana 6 (13 al 19 de abril)</b>                       | <b>13</b> |
| 6.1. Miércoles 15 de abril . . . . .                         | 13        |
| 6.2. Viernes 17 de abril . . . . .                           | 14        |
| <b>7. Semana 7 (20 al 26 de abril)</b>                       | <b>15</b> |
| 7.1. Jueves 16 de abril . . . . .                            | 15        |
| <b>8. Semana 8 (27 de abril al 3 de mayo)</b>                | <b>16</b> |
| 8.1. 8.1. Miércoles 29 de abril . . . . .                    | 16        |
| 8.2. 8.2. Viernes 1 de mayo . . . . .                        | 17        |
| <b>9. Semana 9 (4 al 10 de mayo)</b>                         | <b>18</b> |
| 9.1. 9.1. Miércoles 6 de mayo . . . . .                      | 18        |
| 9.2. 9.2. Viernes 8 de mayo . . . . .                        | 19        |
| <b>10.Semana 10 (11 al 17 de mayo)</b>                       | <b>21</b> |
| 10.1. 10.1. Miércoles 13 de mayo . . . . .                   | 21        |
| 10.2. 10.2. Viernes 15 de mayo . . . . .                     | 22        |
| <b>11.Semana 11 (18 al 24 de mayo)</b>                       | <b>24</b> |
| 11.1. Miércoles 20 de mayo . . . . .                         | 24        |
| 11.2. Viernes 22 de mayo . . . . .                           | 25        |
| <b>12.Semana 12 (25 al 31 de mayo)</b>                       | <b>26</b> |
| 12.1. Lunes 25 de mayo . . . . .                             | 26        |

|                                         |           |
|-----------------------------------------|-----------|
| <b>13.Semana 13 (1 al 7 de junio)</b>   | <b>27</b> |
| 13.1. Lunes 1 de junio . . . . .        | 27        |
| 13.2. Miércoles 3 de junio . . . . .    | 28        |
| <b>14.Semana 14 (8 al 14 de junio)</b>  | <b>29</b> |
| 14.1. Miércoles 10 de junio . . . . .   | 29        |
| <b>15.Semana 15 (15 al 21 de junio)</b> | <b>30</b> |
| 15.1. Lunes 15 de junio . . . . .       | 30        |
| <b>16.Semana 16 (22 al 28 de junio)</b> | <b>31</b> |
| 16.1. Miércoles 24 de junio . . . . .   | 31        |

## Introducción y Resumen del Proyecto

El presente documento constituye la bitácora oficial de actividades y avances del Proyecto Eléctrico titulado *Diseño e Implementación de un Protocolo Reproducible de Evaluación de Similitud de Voz para Sistemas TTS y Voice Conversion*, desarrollado en el marco del laboratorio **LAPA-CR** de la Escuela de Ingeniería Eléctrica de la Universidad de Costa Rica.

### Objetivos del Proyecto

- **Objetivo General:** Diseñar, implementar y validar un protocolo reproducible de evaluación de similitud de voz entre señales naturales y sintéticas, utilizando métricas objetivas y pruebas perceptuales básicas, con énfasis en aplicaciones de tecnologías de voz asistiva en español costarricense.
- **Objetivos Específicos:**
  - Analizar el estado del arte en evaluación de similitud de voz y preservación de identidad, revisando métricas como MCD y embeddings de hablante.
  - Implementar un pipeline básico reproducible para extraer embeddings y calcular similitud coseno dentro del repositorio `voice-similarity-eval`.
  - Construir un conjunto piloto de evaluación con voces naturales de referencia y versiones sintéticas generadas mediante TTS o Voice Conversion.
  - Diseñar y ejecutar una prueba perceptual básica de tipo MOS o ABX con oyentes voluntarios bajo principios éticos.
  - Analizar la correlación preliminar entre métricas objetivas y juicios perceptuales para establecer una línea base experimental.

### Entregables Principales

Al finalizar el proyecto, se constará de los siguientes productos técnicos:

1. **Repositorio de Código:** Repositorio en GitHub (`voice-similarity-eval`) con los scripts de extracción biométrica y análisis estadístico.
2. **Documentación del Protocolo:** Especificaciones técnicas y pasos a seguir para garantizar que los experimentos sean reproducibles en el laboratorio.
3. **Dataset Piloto:** Un conjunto de muestras de audio (voces reales y clonadas) estandarizadas a 16 kHz en formato monoaural.
4. **Análisis de Resultados:** Matrices de similitud y gráficas de rendimiento para definir los umbrales de decisión del sistema.

### Estructura del Reporte

Esta bitácora detalla cronológicamente la planificación, la resolución de incompatibilidades de entorno de software, el diseño de scripts lógicos en Python y la consolidación de los resultados numéricos obtenidos a lo largo de las semanas de experimentación.

## 1. Semana 1: 9 al 15 de marzo

### 1.1. Lunes 9 y Miércoles 11

- **Horas trabajadas:** 1:00 pm - 3:00 pm.
- **Objetivos:**
  - Comprender la metodología de evaluación y los entregables administrativos del curso IE-0499.
  - Formalizar el tema de investigación y los objetivos específicos con el profesor guía.
  - Realizar una lectura exploratoria de la base científica del proyecto.

#### **Actividades Realizadas**

- Asistencia a la clase introductoria para revisar el cronograma oficial y el sistema de evaluación.
- Comunicación con el profesor Marvin Coto para la asignación del proyecto: "Diseño e Implementación de un Protocolo Reproducible de Evaluación de Similitud de Voz para Sistemas TTS y Voice Conversion".
- Revisión de los artículos AI-determined similarity increases likability and trustworthiness y Automatic voice similarity evaluation for TTS, enviados por el profesor guía.

#### **Resultados**

- Definición clara de la ruta de trabajo: énfasis en la reproducibilidad y el uso de métricas objetivas frente a perceptuales.
- Establecimiento de las herramientas base: repositorio modular voice-similarity-eval y uso de Python para el pipeline.

#### **Dificultades encontradas**

- Diría que la dificultad fue asimilar la diferencia conceptual entre similitud de voz (identidad) e inteligibilidad (claridad).

## 2. Semana 2 (16 al 22 de marzo)

### 2.1. Miércoles 18 de marzo

- **Horas trabajadas:** 11:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Investigar los fundamentos matemáticos de los *Speaker Embeddings* y su validez en la percepción humana.
  - Comparar arquitecturas de extracción de identidad para definir el “Back-End” del pipeline.
- **Actividades Realizadas:**
  - Realicé un análisis profundo del artículo de *PLOS ONE* sobre la correlación entre la Similitud Coseno de vectores de voz y juicios de confianza.
  - Se estudiaron profundamente las arquitecturas, como la diferenciación entre *d-vectors* y *x-vectors*, también se investigó de modelos SSL como **WavLM-Large**.
  - Se realizó la derivación de la fórmula de similitud coseno  $S_c$  para la comparación de vectores de alta dimensionalidad en el espacio de identidad.
- **Resultados:**
  - Se tomó la decisión técnica de utilizar arquitecturas d-vector por el artículo leído y por discusión con el profesor, esto porque vamos a trabajar con audios de corta duración y en español costarricense.
- **Dificultades encontradas:**
  - me tomó un rato entender cómo las redes neuronales profundas logran que el embedding sea independiente del contenido del texto y se centre únicamente en las características biofísicas del hablante.

## 2.2. Viernes 20 de marzo

- **Horas trabajadas:** 9:00 a.m. – 1:00 p.m.
- **Objetivos:**
  - Estudiar métricas objetivas de distorsión espectral y modelos predictivos de calidad de voz.
- **Actividades Realizadas:**
  - Revisar el artículo de *JET* sobre evaluación automática en sistemas TTS y Voice Conversion.
  - Análisis del **Mel Cepstral Distortion (MCD)** y su cálculo mediante la distancia euclidiana de vectores MFCC alineados globalmente.
  - Investigación del modelo **NISQA** (*Non-Intrusive Speech Quality Assessment*) para obtener una predicción objetiva del MOS sin necesidad de audios de referencia perfectos.
- **Resultados:**
  - Se definió el set de métricas final del protocolo: MCD para fidelidad acústica, Similitud Coseno para identidad y NISQA para factor perceptual de calidad y similitud.
- **Dificultades encontradas:**
  - Comprender la naturaleza “no intrusiva” de NISQA y cómo sus redes profundas logran predecir la calificación humana de forma autónoma.

### 3. Semana 3 (23 al 29 de marzo)

#### 3.1. Miércoles 25 de marzo

- **Horas trabajadas:** 11:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Diseñar la arquitectura final del pipeline de evaluación para el repositorio `voice-similarity-eval`.
  - Integrar la lógica forense de detección de anomalías (deepfakes) propuesta por el profesor Marvin.
- **Actividades Realizadas:**
  - Se elaboró el diagrama de bloques matemático detallado, el cual integra las fases que suceden en el protocolo.
  - Se definió la lógica de “Fusión SASV” para marcar alertas cuando la similitud de identidad es alta pero la autenticidad es baja.
- **Resultados:**
  - Se realizó de manera correcta el diagrama junto con su lógica para poder entender de manera correcta como se va a realizar el trabajo, además se montaron varios aspectos de estos en el documento de revisión técnica.
- **Dificultades encontradas:**
  - Equilibrar el diseño para que sea meramente de análisis temporal global, evitando la dependencia de alineamientos temporales punto a punto (DTW). Por lo que se fue mejor con los análisis de gráficas.




Figura 1: Diagrama de Bloques del protocolo.



### 3.2. Viernes 27 de marzo

- **Horas trabajadas:** 9:00 a.m. – 1:00 p.m.
- **Objetivos:**
  - Finalizar el borrador del **Documento de Revisión Técnica** en formato IEEE LaTeX.
  - Documentar las implicaciones éticas y forenses del proyecto.
- **Actividades Realizadas:**
  - Se redactó la sección de Discusión Ética centrada en el consentimiento informado y el riesgo de suplantación de identidad vocal.
  - Se colocaron y definieron bien los objetivos y el marco técnico en la plantilla de Overleaf.
  - Se analizaron los datos clave para el reporte de riesgo del sistema y el análisis de clusters (t-SNE).
- **Resultados:**
  - Casi se terminó el borrador documento de revisión técnica, faltaría ver unos aspectos generales con el profesor para montarlo de manera definitiva y corregirlo si ser necesario.
- **Dificultades encontradas:**
  - Sintetizar la amplia base teórica investigada en el espacio recomendado por el profesor (alrededor de dos páginas).

## 4. Semana 4 (30 de marzo a 5 de abril) - Semana Santa

### 4.1. viernes 3 de abril

- **Horas trabajadas:** 9:00 a.m. – 1:00 p.m.
- **Objetivos:**
  - Revisar aspectos del documento borrador.
- **Actividades Realizadas:**
  - Terminar de poner algunas generalidades y corregir texto del borrador.
- **Resultados:**
  - Se completó el borrador, por lo que solo queda que el profesor lo revise.
- **Dificultades encontradas:**
  - NA

## 5. Semana 5 (6 al 12 de abril)

### 5.1. Miércoles 8 de abril

- **Horas trabajadas:** 11:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Realizar el envío formal de la documentación técnica de revisión técnica (Entregable Semana 4).
  - Preparar el entorno de desarrollo práctico para el análisis de los repositorios base.
- **Actividades Realizadas:**
  - Se realizó la revisión final de ortografía, formato IEEE (LaTeX) y consistencia matemática de las métricas ( $S_c$ , MCD, NISQA) en el documento.
  - Se generó el PDF final y se realizó el envío formal vía correo electrónico al profesor Marvin Coto Jiménez.
  - Se hizo la configuración inicial del servidor de cómputo con Conda, instalando las librerías base necesarias (PyTorch, NumPy, Librosa, TensorFlow-io).
- **Resultados:**
  - Documento técnico de revisión técnica enviado satisfactoriamente para la evaluación de la Semana 4.
  - Entorno de desarrollo base configurado y funcional para la fase de implementación práctica.
- **Dificultades encontradas:**
  - La configuración del entorno tomó un poco más de lo esperado.

## 5.2. Viernes 10 de abril

- **Horas trabajadas:** 9:00 a.m. – 1:00 p.m.
- **Objetivos:**
  - Iniciar la fase práctica mediante el análisis forense del repositorio `nisqa`.
  - Verificar la compatibilidad técnica del repositorio base con el pipeline de análisis temporal global definido para español costarricense.
- **Actividades Realizadas:**
  - Se realizó la clonación y auditoría detallada de la estructura del repositorio NISQA ([github.com/GabrielMittag/NISQA](https://github.com/GabrielMittag/NISQA)).
  - Análisis forense de la arquitectura de la red profunda (CNN-VGG) definida en `nisqa/model.py` para comprender cómo NISQA procesa la frase completa y extrae características temporales profundas.
  - Se hizo el estudio de los scripts de inferencia (`nisqa/run_nisqa.py`) para identificar cómo el modelo predice el puntaje MOS-LQO de forma no intrusiva.
- **Resultados:**
  - Comprensión del funcionamiento interno de NISQA y su integración matemática en el pipeline como métrica perceptual profunda.
- **Dificultades encontradas:**
  - Complejidad técnica para interpretar cómo NISQA maneja internamente las tramas de audio de duración variable dentro de su arquitectura DNN para extraer características globales.

## 6. Semana 6 (13 al 19 de abril)

### 6.1. Miércoles 15 de abril

- **Horas trabajadas:** 11:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Sincronización con el repositorio oficial del laboratorio (LAPA-CR).
  - Configuración del pipeline de extracción de características vocales.
- **Actividades Realizadas:**
  - Se realizó la sincronización técnica con el repositorio oficial `LAPA-CR/voice-similarity-eval`.
  - Verificación de las dependencias requeridas mediante el archivo `requirements.txt` para asegurar la compatibilidad con el entorno `ise-protocol`.
  - Configuración de la arquitectura de directorios para la gestión de *datasets* locales y pesos de modelos pre-entrenados.
- **Resultados:**
  - Entorno de desarrollo sincronizado con la estructura oficial del laboratorio y pipeline listo para integración de modelos.
- **Dificultades encontradas:**
  - Resolución de permisos de acceso en repositorios Git mediante la transición al repositorio público oficial.

## 6.2. Viernes 17 de abril

- **Horas trabajadas:** 9:00 a.m. – 1:00 p.m.
- **Objetivos:**
  - Implementación del modelo de extracción de *embeddings* (ECAPA-TDNN).
  - Optimización de la ejecución mediante aceleración por hardware (GPU).
- **Actividades Realizadas:**
  - Configuración del entorno de inferencia para operar sobre la GPU NVIDIA mediante tensores CUDA.
  - Integración del modelo ECAPA-TDNN (SpeechBrain) para la generación de *d-vectors* de 192 dimensiones.
  - Programación de la métrica de Similitud Coseno ( $\cos(\theta)$ ) para la validación de identidad vocal.
- **Resultados:**
  - Pipeline funcional con capacidad de procesamiento paralelo, logrando tiempos de inferencia inferiores a 100ms.
  - Validación preliminar del algoritmo de comparación de identidades.
- **Dificultades encontradas:**
  - Ajuste de la topología de red para el manejo eficiente de datos en la VRAM de la GPU.

## 7. Semana 7 (20 al 26 de abril)

### 7.1. Jueves 16 de abril

- **Horas trabajadas:** 10:00 a.m. – 6:00 p.m.
- **Objetivos:**
  - Toma de archivos de prueba de audio para usar en el pipeline.
  - Configuración de los archivos de prueba en .wav para que puedan funcionar de manera correcta.
  - guardar todos los archivos en una carpeta local para luego ser clonados al repositorio `voice-similarity-eval`.
- **Actividades Realizadas:**
  - Se tomaron algunas de las muestras de audio que se van a usar como prueba para el pipeline.
  - Se verificó que los archivos de prueba estuvieran en el formato correcto (.wav) y los que no lo estaban se convirtieron.
  - Se guardaron en la carpeta local los archivos de prueba para luego poder clonarlos en el repositorio y seguidamente probarlos.
- **Resultados:**
  - Se obtuvieron algunos archivos de prueba de audio para verificar el correcto comportamiento del pipeline.
- **Dificultades encontradas:**
  - la toma de datos tomó un poco más de tiempo de lo esperado.

## 8. Semana 8 (27 de abril al 3 de mayo)

### 8.1. 8.1. Miércoles 29 de abril

- **Horas trabajadas:** 11:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Finalizar el script de inferencia automatizada para el cálculo de Similitud Coseno.
  - Depurar errores de compatibilidad entre las librerías de Deep Learning y el hardware local.
- **Actividades Realizadas:**
  - Desarrollo y depuración del script `comparar_voces.py` utilizando el modelo ECAPA-TDNN de SpeechBrain.
  - Resolución de conflictos de versión en PyTorch, específicamente en el módulo `torch.amp`, para asegurar la compatibilidad con los tensores de la GPU.
  - Ajuste de la lógica de procesamiento para convertir tensores de alta dimensionalidad (192 elementos) en escalares de similitud mediante la métrica de Similitud Coseno ( $S_c$ ).
- **Resultados:**
  - Script de inferencia totalmente funcional bajo el entorno `ise-protocol`.
  - Optimización del tiempo de ejecución mediante el uso de núcleos CUDA:0.
- **Dificultades encontradas:**
  - Errores de sintaxis en la gestión de dispositivos CUDA debido a cambios en la API de la versión 1.0 de SpeechBrain.



## 8.2. 8.2. Viernes 1 de mayo

- **Horas trabajadas:** 9:00 a.m. – 2:00 p.m.
- **Objetivos:**
  - Validar el protocolo mediante pruebas cruzadas con el dataset local.
  - Sincronizar el progreso técnico con el repositorio oficial del laboratorio (LAPA-CR).
- **Actividades Realizadas:**
  - Ejecución de pruebas de identidad: comparación de referencia maestra contra audios de prueba propios y de terceros.
  - Análisis de resultados: obtención de similitud promedio de  $\sim 0,64$  para la misma identidad y  $\sim 0,05$  para locutores distintos.
  - Configuración de un Personal Access Token (PAT) para resolver errores de autenticación (Error 403) en Git.
- **Resultados:**
  - Primer *commit* exitoso al repositorio `voice-similarity-eval`, incluyendo script, `.gitignore` y dataset inicial de 11 muestras.
  - Establecimiento de un umbral de decisión (*threshold*) de 0.50 para la validación biométrica.
- **Dificultades encontradas:**
  - Restricciones de seguridad de GitHub que impiden el uso de contraseñas convencionales desde la terminal.

```
Comparando contra referencia: data/raw/daniel_ref1.wav
-----
Test: daniel_test1.wav | Similitud: 0.6458 | IDENTIDAD CONFIRMADA
Test: daniel_test2.wav | Similitud: 0.5104 | IDENTIDAD CONFIRMADA
Test: felipe_test1.wav | Similitud: 0.0312 | ACCESO DENEGADO
Test: felipe_test2.wav | Similitud: 0.0729 | ACCESO DENEGADO
(ise-protocol) daniel@daniel-Victus-by-HP-Gaming-Laptop-15-fb3xxx:~/Proyecto_Ele
ctrico/voice-similarity-eval$
```

Figura 2: Comparación de referencia contra audios de prueba.

## 9. Semana 9 (4 al 10 de mayo)

### 9.1. Miércoles 6 de mayo

- **Horas trabajadas:** 11:00 a.m. – 5:00 p.m.
- **Objetivos:**
  - Integrar un motor de síntesis de voz (*Text-to-Speech*) para generar audios sintéticos mediante clonación de voz.
  - Resolver conflictos de dependencias entre librerías de *Deep Learning* y el entorno local.
- **Actividades Realizadas:**
  - Configuración de un entorno de Conda aislado (**generador-tts**) para gestionar la incompatibilidad de versiones de NumPy entre *Coqui TTS* (1,22,0) y el entorno principal (1,26,4).
  - Implementación del modelo fundacional **XTTS v2** en modalidad *zero-shot* mediante el script `generar_sintetico.py`.
  - Desarrollo de un *Monkey Patch* para la función `torch.load`, desactivando la restricción de seguridad `weights_only` de PyTorch 2.6.
  - Automatización del procesamiento por lotes para extraer identidades únicas de archivos `.wav` y evitar redundancia en la generación.
- **Resultados:**
  - Generación exitosa de muestras sintéticas para los locutores de prueba con alta fidelidad tonal.
  - Estabilización del entorno de ejecución mediante el aislamiento de dependencias críticas.
- **Dificultades encontradas:**
  - Conflictos estrictos en el ecosistema de Python que requerían el uso de múltiples entornos virtuales para mantener la integridad de los modelos.

## 9.2. 9.2. Viernes 8 de mayo

- **Horas trabajadas:** 9:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Evaluar cuantitativamente la vulnerabilidad del sistema ante ataques de clonación.
  - Sincronizar el progreso técnico actualizado con el repositorio oficial del laboratorio.
- **Actividades Realizadas:**
  - Normalización de muestras sintéticas a 16kHz/mono para asegurar compatibilidad con el extractor de *embeddings* ECAPA-TDNN.
  - Creación del script `visualizar_resultados.py` para el cálculo de similitud coseno cruzada y generación de mapas de calor.
  - Configuración de archivos de control de versiones (`.gitignore`) para excluir directorios binarios de gran tamaño.
  - Ejecución del flujo de trabajo *Fork/Pull Request* para la integración formal de cambios en la rama principal del laboratorio.
- **Resultados:**
  - Obtención de una matriz de similitud que evidencia correlaciones de hasta 0,69 entre voces sintéticas y reales.
  - Sincronización exitosa del framework base y el dataset piloto en el repositorio remoto.
- **Dificultades encontradas:**
  - Errores de transferencia de memoria entre GPU (*CUDA*) y CPU durante la conversión de tensores para visualización de datos.




Figura 3: Matriz de Similitud de Voz generada mediante el clasificador ECAPA-TDNN, comparando muestras genuinas naturales y sintéticas.

## 10. Semana 10 (11 al 17 de mayo)

### 10.1. 10.1. Miércoles 13 de mayo

- **Horas trabajadas:** 10:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Implementar el análisis estadístico de los resultados de similitud mediante el cálculo del *Equal Error Rate* (EER).
  - Evaluar el rendimiento del modelo biométrico en la distinción entre voces genuinas y ataques sintéticos.
- **Actividades Realizadas:**
  - Desarrollo del script general `calcular_eer_general.py`, el cual automatiza el flujo completo. Este se encarga de leer dinámicamente el directorio de audios, extraer los embeddings con ECAPA-TDNN y auto-etiquetar las comparaciones basándose en la nomenclatura del archivo, permitiendo escalar el dataset sin *hardcodear* valores.
  - Clasificación de los puntajes extraídos en distribuciones, como usuarios genuinos e impostores/clones.
  - Programación de la lógica para calcular la Tasa de Falsos Positivos (FPR) y la Tasa de Falsos Negativos (FNR) variando el umbral de decisión.
- **Resultados:**
  - Script dinámico funcional que procesó automáticamente el dataset, logrando evaluar 79 cruces válidos de forma autónoma y sin intervención manual.
- **Dificultades encontradas:**
  - Errores iniciales de rutas relativas (*paths*) al intentar ejecutar el script fuera del directorio raíz del repositorio, lo que impedía la lectura correcta de la carpeta `data/raw/`.

## 10.2. 10.2. Viernes 15 de mayo

- **Horas trabajadas:** 9:00 a.m. – 2:00 p.m.
- **Objetivos:**
  - Definir el umbral biométrico definitivo para el protocolo de evaluación.
  - Graficar la Curva ROC (*Receiver Operating Characteristic*) para la documentación del proyecto.
- **Actividades Realizadas:**
  - Ejecución del análisis EER final sobre la totalidad de la matriz de audios evaluada (locutores naturales y clones generados por XTTS v2).
  - Generación y exportación de la gráfica de la Curva ROC (`curva_roc_final.png`) utilizando `matplotlib`.
  - Respaldo del código analítico en GitHub mediante el flujo de control de versiones establecido en el Fork personal.
- **Resultados:**
  - Obtención de un umbral matemático exacto (*Threshold*) de **0.6941**, estableciendo la frontera formal de aceptación del sistema biométrico.
  - Cálculo de un *Equal Error Rate* (EER) del **8.33 %**, demostrando una alta precisión inicial del protocolo en la separación de voces legítimas y ataques sintéticos.
  - Integración exitosa de la gráfica ROC a la documentación oficial.
- **Dificultades encontradas:**
  - Ajuste en las dependencias para el manejo de los parámetros vacíos, los cuales disparaban excepciones matemáticas (*ValueError*) durante el cálculo preliminar de la curva.




Figura 4: Curva ROC (Receiver Operating Characteristic) para el protocolo de similitud de voz, ilustrando el rendimiento del sistema con un umbral óptimo de 0.6941 y un Equal Error Rate (EER) del 8.33 %.

## 11. Semana 11 (18 al 24 de mayo)

### 11.1. Miércoles 20 de mayo

- **Horas trabajadas:** 10:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Desarrollar el módulo de evaluación de distorsión espectral para cumplir con los requerimientos del diagrama de bloques establecido en la documentación técnica.
  - Implementar el algoritmo de Mel Cepstral Distortion (MCD) utilizando técnicas de alineamiento temporal.
- **Actividades Realizadas:**
  - Desarrollo del script `calcular_mcd.py` apoyado en la librería `librosa` para el análisis acústico en el dominio de la frecuencia.
  - Implementación de la etapa de Pre-procesamiento Global (VAD - *Voice Activity Detection*) para recortar silencios absolutos en las señales mediante umbrales de energía (20 dB).
  - Extracción de 13 coeficientes MFCC y aplicación del algoritmo *Dynamic Time Warping* (DTW) para alinear matemáticamente las asimetrías temporales.
- **Resultados:**
  - Pipeline de análisis espectral totalmente funcional, logrando procesar de manera automatizada las referencias reales y los clones sintéticos.
  - Obtención de un MCD promedio de 514.35 dB. Se ajustó el criterio de evaluación documentando que la magnitud absoluta difiere del estándar teórico debido a las diferencias en la base de logaritmos ( $\ln$  vs  $\log_{10}$ ) nativa de la librería `librosa`.
- **Dificultades encontradas:**
  - Incompatibilidad de la librería `librosa` con la versión reciente de `setuptools` (v82), lo que generó un `ModuleNotFoundError`. Se resolvió realizando un *downgrade* forzado del paquete a una versión anterior estable ( $< 70$ ).
  - Distorsiones matemáticas extremas iniciales debido a la comparación de silencios absolutos por parte del algoritmo DTW. Se mitigó de forma exitosa mediante la integración del bloque VAD especificado en la documentación oficial.



## 11.2. Viernes 22 de mayo

- **Horas trabajadas:** 1:00 p.m. – 5:00 p.m.
- **Objetivos:**
  - Completar la arquitectura del protocolo de evaluación implementando la métrica objetiva perceptual NISQA, de acuerdo con el diagrama de bloques.
  - Automatizar la lectura y procesamiento de los audios para predecir su naturalidad en la escala MOS (*Mean Opinion Score*).
- **Actividades Realizadas:**
  - Descarga e integración del repositorio y pesos neuronales del modelo NISQA (*Non-Intrusive Speech Quality Assessment*) como submódulo del proyecto.
  - Desarrollo del script `calcular_mos_nisqa.py` para direccionar el dataset a la red neuronal y procesar el archivo `.csv` de resultados mediante la librería `pandas`.
  - Corrección de la lógica de filtrado en el script `visualizar_resultados.py` para permitir la lectura y remuestreo de los audios clonados con XTTS en la generación del mapa de calor de ECAPA-TDNN.
  - Implementación de la creación automática de directorios (`os.makedirs`) en el script principal para el manejo de excepciones de salida.
- **Resultados:**
  - Integración exitosa del 100 % de las métricas objetivas (Similitud Coseno, MCD y NISQA) planteadas en el marco metodológico.
  - Se obtuvo una predicción MOS promedio de 3.93 / 5.00 para las locuciones naturales y de 3.75 / 5.00 para las versiones sintéticas generadas con XTTS v2, demostrando alta naturalidad y calidad en la clonación.
- **Dificultades encontradas:**
  - Falla de guardado de la librería `pandas` (`OSError`) al intentar exportar los resultados a un directorio inexistente, lo que requirió programar la creación forzada de la carpeta de salida desde Python antes de la ejecución de la red neuronal.

## 12. Semana 12 (25 al 31 de mayo)

### 12.1. Lunes 25 de mayo

- **Horas trabajadas:** 8:00 a.m. – 12:00 m.d.
- **Objetivos:**
  - Refactorizar la arquitectura del repositorio para cumplir con los estándares de control de versiones y separar lógicamente los módulos de generación, evaluación y salida de datos.
  - Automatizar la ejecución secuencial del protocolo de métricas objetivas mediante la implementación de un archivo `Makefile`.
  - Desarrollar un módulo de visualización espectral para comparar cualitativamente las frecuencias de los audios naturales frente a los vectores clonados.
- **Actividades Realizadas:**
  - Reorganización completa del espacio de trabajo, aislando el código fuente en la carpeta `scripts/` (subdividida en `generacion` y `evaluacion`) y dirigiendo todos los artefactos generados a la carpeta `outputs/`.
  - Programación del archivo `Makefile` en la raíz del proyecto para centralizar el pipeline. Se definieron las recetas `identidad`, `frecuencia`, `calidad` y el comando global `make all`.
  - Desarrollo del script independiente `graficar_espectrogramas.py` utilizando `librosa.display` y `matplotlib` para generar y exportar Espectrogramas de Mel (*Mel-Spectrograms*) de las locuciones evaluadas.
- **Resultados:**
  - Repositorio altamente escalable y automatizado, reduciendo el riesgo de errores de ejecución humana durante la fase de pruebas del sistema.
  - Generación exitosa de gráficas espectrales comparativas. El análisis visual confirmó que el modelo XTTS v2 logra una replicación casi idéntica de los formantes de voz en las frecuencias bajas y medias, presentando únicamente una leve atenuación en la banda de altas frecuencias ( $> 4096$  Hz).
- **Dificultades encontradas:**
  - Colapso de la librería gráfica (`AttributeError`) provocado por un conflicto de *lazy loading* interno en `librosa` al intentar instanciar los ejes de los subgráficos. El problema se solucionó alterando la jerarquía de dependencias en el script, forzando a Python a cargar `matplotlib.pyplot` en memoria antes de inicializar el motor de análisis de audio.

## 13. Semana 13 (1 al 7 de junio)

### 13.1. Lunes 1 de junio

- **Horas trabajadas:** 9:00 a.m. – 2:00 p.m.
- **Objetivos:**
  - Ampliar el banco de pruebas con nuevas identidades (voces) para hacer el experimento más robusto y estadísticamente válido.
  - Generar los clones sintéticos de las nuevas voces y actualizar todas las gráficas del proyecto.
- **Actividades Realizadas:**
  - Recolección de 4 audios reales nuevos correspondientes a dos personas adicionales.
  - Conversión y limpieza de los audios al formato estricto requerido por el sistema (.wav, 16 kHz, mono) utilizando comandos de `ffmpeg`.
  - Generación de las versiones sintéticas de estas nuevas voces utilizando el modelo XTTS v2 en el entorno de conda correspondiente.
  - Ejecución del protocolo automatizado completo (`make all`) para recalcular la curva ROC, las distancias acústicas y las notas NISQA con el dataset ampliado.
- **Resultados:**
  - Dataset expandido exitosamente a 4 identidades distintas.
  - Gráficas de similitud y métricas objetivas actualizadas automáticamente con la integración de los nuevos locutores.
- **Dificultades encontradas:**
  - Complicaciones con la organización de los nuevos archivos de audio, pero se lograron acomodar en la carpeta del proyecto.

### 13.2. Miércoles 3 de junio

- **Horas trabajadas:** 10:00 a.m. – 3:00 p.m.
- **Objetivos:**
  - Diseñar y distribuir el formulario de evaluación perceptual humana para poder comparar la opinión de las personas con los resultados de la Inteligencia Artificial.
- **Actividades Realizadas:**
  - Configuración de un Google Forms estructurado en dos partes: Prueba MOS (para calificar qué tan natural suena el audio) y Prueba ABX (para calificar qué tanto se parece el clon a la persona original).
  - Implementación de un diseño experimental, donde los encuestados evalúan los audios mediante números, sin saber si son reales o generados por computadora.
  - Subida de todos los audios a una carpeta pública de Google Drive y vinculación de los enlaces a cada pregunta del formulario.
  - Redacción y envío del correo oficial al profesor guía, junto con la distribución del enlace a compañeros para iniciar la recolección de datos.
- **Resultados:**
  - Instrumento de evaluación subjetiva finalizado, aprobado y en etapa activa de recolección de respuestas.
  - link del forms: <https://forms.gle/mhWqJgYus6pmdkjR7>
- **Dificultades encontradas:**
  - La plataforma de Google Forms no permite incrustar archivos de audio directamente, lo que obligó a estructurar la prueba usando enlaces externos de Drive y configurar cuidadosamente los permisos de acceso para no interrumpir la encuesta.

## 14. Semana 14 (8 al 14 de junio)

### 14.1. Miércoles 10 de junio

- **Horas trabajadas:** 9:00 a.m. – 3:00 p.m.
- **Objetivos:**
  - Procesar los datos recolectados mediante el formulario de evaluación perceptual humana.
  - Elaborar el informe técnico de análisis comparativo, contrastando los juicios humanos con las métricas objetivas computacionales.
- **Actividades Realizadas:**
  - Análisis estadístico de los resultados de las pruebas MOS y ABX extraídos de las respuestas de los 25 participantes en el formulario.
  - Evaluación matemática de la correlación entre las estimaciones no intrusivas de naturalidad (modelo NISQA) y los resultados de la prueba humana MOS.
  - Comparación de la distancia espectral MCD con el porcentaje de éxito en el reconocimiento de identidades en la prueba ABX.
  - Redacción del informe técnico documentando los resultados cuantitativos y evaluando las limitaciones del diseño experimental.
- **Resultados:**
  - Identificación de una fuerte correlación positiva entre las predicciones de NISQA (promedio superior a 4.0/5.0) y los puntajes de naturalidad MOS humanos.
  - Determinación de una relación inversamente proporcional entre el MCD y el reconocimiento en la prueba ABX, observando que los clones lograron engañar a los evaluadores en más del 85 % de los casos.
  - Informe técnico comparativo completado con éxito y listo para revisión.
- **Dificultades encontradas:**
  - Identificación de limitaciones metodológicas debido al tamaño de la muestra (limitada a 4 identidades) y la presencia de ruido de fondo o reverberación en los audios originales, lo cual afectó levemente el cálculo inicial del MCD.

## 15. Semana 15 (15 al 21 de junio)

### 15.1. Lunes 15 de junio

- **Horas trabajadas:** 10:00 a.m. – 4:00 p.m.
- **Objetivos:**
  - Consolidar la arquitectura del proyecto y documentar el protocolo definitivo de evaluación.
  - Desarrollar el informe final técnico integrador incluyendo la síntesis de resultados y la hoja de ruta para trabajo futuro.
- **Actividades Realizadas:**
  - Documentación exhaustiva de la arquitectura del pipeline (ingesta en data/raw, separación lógica en scripts y salida en outputs) orquestado de forma completa mediante el archivo Makefile.
  - Estructuración final del repositorio voice-similarity-eval, verificando que todo el código fuente contenga los debidos comentarios internos y guías de reproducibilidad.
  - Redacción de la síntesis de resultados para el informe final, detallando el flujo híbrido de generación zero-shot (XTTS v2), evaluación objetiva (MCD, Similitud Coseno, NISQA) y subjetiva.
  - Diseño de una hoja de ruta técnica que propone la expansión del banco de pruebas, inyección de ruido controlado (Gaussian Noise) y comparación contra otros modelos de síntesis (VITS o RVC).
- **Resultados:**
  - Repositorio de GitHub completamente estructurado, comentado y documentado para asegurar su escalabilidad en el laboratorio LAPA-CR.
  - Informe final técnico integrador concluido, confirmando la alta viabilidad del modelo XTTS v2 para tareas de clonación de voz en español costarricense.
  - Hoja de ruta formalizada como base para la expansión del proyecto a estudios de robustez y mayor escala.
- **Dificultades encontradas:**
  - Sintetizar toda la arquitectura de software y el volumen de resultados del análisis correlacional en un documento integrador conciso requirió múltiples iteraciones de redacción técnica.

## 16. Semana 16 (22 al 28 de junio)

### 16.1. Miércoles 24 de junio

- **Horas trabajadas:** 10:00 a.m. – 11:00 a.m.
- **Objetivos:**
  - Presentar los informes, repositorio y protocolo funcional al profesor Marvin.
  - Ver aspectos finales para aprobar el último pull-request al repositorio voice-similarity-eval de LAPA CR.
- **Actividades Realizadas:**
  - Se realizó una última reunión con el profesor Marvin Coto para ver lo que se llegó a completar con este proyecto eléctrico y formalizar el cierre del mismo.
- **Resultados:**
  - Finalización del proyecto eléctrico.