

Diseño e Implementación de un Protocolo Reproducible de Evaluación de Similitud de Voz para Sistemas TTS y Voice Conversion

Proyecto Eléctrico - Escuela de Ingeniería Eléctrica - UCR.

Daniel Valverde Ortiz
Escuela de Ingeniería Eléctrica
Universidad de Costa Rica
San José, Costa Rica
daniel.valverdeortiz@ucr.ac.cr

Marvin Coto Jiménez
Departamento de Automática
Escuela de Ingeniería Eléctrica, UCR
San José, Costa Rica
marvin.coto@ucr.ac.cr

Abstract—Este documento presenta el marco técnico y metodológico para el desarrollo de un protocolo reproducible destinado a la evaluación de similitud de voz en tecnologías de síntesis de habla (TTS) y conversión de voz. El proyecto aborda la necesidad de establecer métricas estándar que correlacionen el análisis computacional mediante embeddings de hablante y la percepción auditiva humana, con un enfoque particular en el idioma español costarricense para aplicaciones asistivas.

Index Terms—Procesamiento de voz, embeddings de hablante, similitud de voz, TTS, español costarricense, métricas objetivas.

I. INTRODUCCIÓN

El avance de la Inteligencia Artificial ha permitido la generación de voces sintéticas altamente realistas. No obstante, la evaluación de la "identidad del hablante" sigue siendo un reto técnico. Este proyecto busca formalizar un protocolo que sea ejecutable y comparable por otros investigadores, asegurando rigor científico y trazabilidad.

II. OBJETIVOS

A. Objetivo General

Diseñar, implementar y validar un protocolo reproducible de evaluación de similitud de voz entre señales naturales y sintéticas, utilizando métricas objetivas y pruebas perceptuales básicas, con énfasis en aplicaciones de tecnologías de voz asistiva en español costarricense.

B. Objetivos Específicos

- Analizar el estado del arte en evaluación de similitud de voz y preservación de identidad, revisando métricas como MCD y embeddings de hablante.
- Implementar un pipeline básico reproducible para extraer embeddings y calcular similitud coseno dentro del repositorio *voice-similarity-eval*.
- Construir un conjunto piloto de evaluación con voces naturales de referencia y versiones sintéticas generadas mediante TTS o Voice Conversion.

- Diseñar y ejecutar una prueba perceptual básica de tipo MOS o ABX con oyentes voluntarios bajo principios éticos.
- Analizar la correlación preliminar entre métricas objetivas y juicios perceptuales para establecer una línea base experimental.

III. METODOLOGÍA Y MARCO TÉCNICO DEL PROTOCOLO

El protocolo propuesto se fundamenta en un flujo de procesamiento que garantiza la integridad de la identidad vocal desde la señal de entrada hasta la obtención de una métrica de similitud. El diseño se divide en las fases de caracterización de identidad, evaluación objetiva de calidad y validación perceptual.




Fig. 1. Arquitectura del protocolo de evaluación de similitud de voz.

Como se ilustra en la Fig. 1, el sistema procesa de forma paralela señales nativas y sintéticas. Tras una etapa de pre-procesamiento global que incluye normalización y detección de actividad de voz (VAD), las señales son caracterizadas mediante coeficientes MFCC para la extracción de identidad y calidad. Este flujo estructurado permite que cada módulo funcione de manera independiente, facilitando la reproducibilidad del protocolo en diferentes entornos de desarrollo.

A. Fundamentos Matemáticos de los Speaker Embeddings

La caracterización de la identidad del hablante en sistemas de clonación de voz y conversión de habla se basa principalmente en dos enfoques: *speaker adaptation* y *speaker encoding* [2]. Mientras que la adaptación requiere ajustar los parámetros de un modelo pre-entrenado con grandes cantidades de datos del hablante objetivo, el enfoque de **speaker encoding** permite inferir una representación compacta (embedding) a partir de una muestra de audio de corta duración. Este último es el núcleo de este protocolo debido a su eficiencia en tiempo y memoria [2].

Para la extracción de estos embeddings, se utiliza la arquitectura de **d-vectors**. Un d-vector es una representación de punto fijo en un espacio de alta dimensionalidad que captura características discriminativas del hablante, tales como el timbre, el tono y el acento [2], [4]. Matemáticamente, el proceso se define mediante una red neuronal profunda (DNN) entrenada con una función de pérdida de extremo a extremo (*GE2E loss*) [4].

Sea $x = \{t_1, t_2, \dots, t_M\}$ una secuencia de tramas de audio representadas mediante coeficientes cepstrales en las frecuencias de Mel (MFCC). El extractor de características f_θ mapea esta secuencia a un vector de identidad e mediante la siguiente operación:

$$e = L_2 \left(\sum_{m=1}^M f_\theta(t_m) \right) \quad (1)$$

Donde f_θ representa las capas ocultas de la red (normalmente celdas LSTM o capas convolucionales) y L_2 indica una normalización de norma euclidiana para asegurar que el embedding resultante se ubique en la superficie de una hipersfera unitaria [4]. Esta normalización es crítica, ya que permite que la comparación entre dos hablantes se simplifique al cálculo de la distancia angular o similitud coseno en dicho espacio vectorial.

Este método de caracterización garantiza que el protocolo sea *text-independent*, es decir, capaz de evaluar la similitud de la voz independientemente del contenido léxico del mensaje, enfocándose exclusivamente en la biometría vocal del sujeto.

B. Métricas Objetivas: Mel Cepstral Distortion (MCD) y NISQA

La evaluación objetiva de la similitud y calidad de voz tradicionalmente ha dependido de algoritmos de alineamiento temporal como *Dynamic Time Warping* (DTW) para comparar señales de distinta duración. Sin embargo, este protocolo propone un análisis basado en el dominio de la frecuencia y modelos de aprendizaje profundo para prescindir de dicho alineamiento.

1) *Mel Cepstral Distortion (MCD)*: El MCD es una medida de distorsión espectral que cuantifica la diferencia entre dos secuencias de coeficientes cepstrales de Mel (MFCC). Esta métrica es fundamental para evaluar qué tan cerca está la

envolvente espectral de la voz sintetizada respecto a la natural [2], [5]. Matemáticamente, para un par de vectores de coeficientes c y c' , el MCD se define como:

$$MCD = \frac{10}{\ln 10} \sqrt{2 \sum_{i=1}^K (c_i - c'_i)^2} \quad (2)$$

Donde K es el número de coeficientes (usualmente 24). Al promediar este valor sobre todos los marcos de la señal, se obtiene una estimación de la fidelidad del timbre vocal. En este protocolo, se prioriza el uso de MCD global sobre segmentos de habla activa detectados por el módulo VAD para mitigar el sesgo por silencios.

2) *NISQA (Speech Quality and Naturalness Assessment)*: Para complementar la métrica de distorsión, se integra el modelo **NISQA**, el cual utiliza una arquitectura de red neuronal profunda para predecir la calidad y naturalidad del habla [3]. La principal ventaja de NISQA en este protocolo es su capacidad para procesar señales de forma no intrusiva y sin requerir una señal de referencia alineada temporalmente [3].

El modelo opera extrayendo características de espectrogramas de Mel que luego son procesadas por capas convolucionales y mecanismos de *self-attention* para capturar dependencias temporales y distorsiones acústicas [3]. El resultado es una puntuación basada en la escala *Mean Opinion Score* (MOS), que proporciona una métrica de naturalidad altamente correlacionada con la percepción humana, fundamental para validar sistemas de TTS y Voice Conversion en el contexto de este protocolo.

Este enfoque dual (MCD para espectro y NISQA para naturalidad) permite una evaluación robusta que identifica si la voz clonada preserva la identidad del hablante original mientras mantiene una calidad auditiva aceptable.

C. Metodologías Perceptuales de Validaciones

La validación final del protocolo requiere la integración de juicios humanos para corroborar la eficacia de las métricas objetivas. Este componente es esencial, ya que se ha demostrado que existe una correlación directa entre la similitud determinada por algoritmos de IA y la percepción humana de confiabilidad y agrado hacia una voz.

1) *Pruebas MOS (Mean Opinion Score)*: La metodología principal de evaluación perceptual consiste en la aplicación de pruebas MOS, donde oyentes voluntarios califican las señales en una escala del 1 al 5. Se evalúan dos dimensiones críticas para el protocolo:

- **Naturalidad**: Grado en que la voz sintética suena como un ser humano real.
- **Similitud de Hablante**: Capacidad del oyente para identificar si la voz sintética pertenece al mismo sujeto de la voz natural de referencia.

2) *Pruebas de Comparación ABX*: Como método complementario, se utilizan pruebas de discriminación ABX. En este esquema, al evaluador se le presentan dos muestras de referencia (A y B) y una muestra de prueba (X). El sujeto debe

determinar si X pertenece al hablante A o B. Esta prueba es particularmente útil para validar la preservación de la identidad vocal en sistemas de *Voice Conversion*, donde la meta es que el embedding del sistema transformado sea indistinguible del original ante el oído humano.

3) *Correlación Objetivo-Perceptual*: El protocolo culmina con un análisis de correlación entre los valores de similitud coseno de los d-vectors, los puntajes de NISQA y los resultados de las pruebas MOS. Una alta correlación entre la métrica de IA y el juicio humano no solo valida la arquitectura técnica, sino que refuerza la percepción de seguridad y veracidad del sistema evaluado.

IV. CONSIDERACIONES ÉTICAS EN LA EVALUACIÓN DE SIMILITUD VOCAL

La implementación de tecnologías de clonación de voz conlleva una dualidad entre el avance tecnológico y el riesgo de seguridad. Como se analiza en la literatura, estas herramientas pueden ser un motor de innovación (*game-changer*) o una amenaza (*threat*) dependiendo de su uso ético y supervisión [2].

A. Detección de Anomalías y Suplantación de Identidad

El principal riesgo ético radica en el uso de voces sintéticas para el fraude, la extorsión y la desinformación [2]. Debido a que la IA puede mimetizar características únicas como el tono y el acento con alta precisión, es posible engañar sistemas de autenticación biométrica y a personas en contextos sociales [2]. Por ello, este protocolo propone la evaluación de similitud no solo para mejorar la síntesis, sino para establecer líneas base que ayuden a distinguir entre voces legítimas y ataques de suplantación (*deepfakes*) [2].

B. Consentimiento Informado y Privacidad

La recolección de datos para extraer *embeddings* de hablante debe regirse por principios estrictos de privacidad:

- **Autorización:** Es obligatorio obtener el consentimiento explícito de los individuos antes de grabar o procesar su identidad vocal [2].
- **Confidencialidad:** Los datos biométricos extraídos (como los d-vectors) deben ser tratados como información sensible, limitando su almacenamiento y acceso para prevenir filtraciones que comprometan la identidad del sujeto [2].
- **Divulgación:** Se debe garantizar la transparencia, informando siempre al usuario final cuando una voz con la que interactúa es de origen sintético [2].

Al equilibrar estos factores, el protocolo asegura que la innovación en voces asistivas para el contexto costarricense se desarrolle bajo un marco de responsabilidad y respeto a los derechos individuales.

REFERENCES

- [1] O. Jaggy, S. Schwan, and H. S. Meyerhoff, "AI-determined similarity increases likability and trustworthiness of human voices," *PLOS ONE*, vol. 20, no. 3, Art. no. e0318890, Mar. 2025. [Online]. Available: <https://doi.org/10.1371/journal.pone.0318890>
- [2] G. G. Genelza, "A systematic literature review on AI voice cloning generator: A game-changer or a threat?," *Journal of Emerging Technologies (JET)*, vol. 4, no. 2, pp. 154–161, 2024. [Online]. Available: <https://doi.org/10.57040/ag587791>
- [3] G. Mittag, B. Naderi, I. Chehadi, and S. Möller, "NISQA: A Deep Learning-Based Model for Objective Speech Quality and Naturalness Assessment," *arXiv preprint arXiv:2104.09494*, 2021.
- [4] L. Wan, Q. Wang, A. Papir, and I. L. Moreno, "Generalized End-to-End Loss for Speaker Verification," *Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2018, pp. 4879–4883.
- [5] W. C. Chu, "Objective Measures of Speech Quality," in *Speech Coding Algorithms: Foundation and Evolution of Standardized Coders*, Hoboken, NJ, USA: Wiley, 2003, pp. 431–450.
- [6] A. González-Docasal and A. Álvarez, "Enhancing Voice Cloning Quality through Data Selection and Alignment-Based Metrics," *Applied Sciences*, vol. 13, no. 14, p. 8049, 2023.