

# Informe Final: Diseño e Implementación de un Protocolo Reproducible de Evaluación de Similitud de Voz

Daniel Valverde Ortiz  
Escuela de Ingeniería Eléctrica  
Universidad de Costa Rica  
San José, Costa Rica  
daniel.valverdeortiz@ucr.ac.cr

Marvin Coto Jiménez  
Departamento de Automática  
Escuela de Ingeniería Eléctrica, UCR  
San José, Costa Rica  
marvin.coto@ucr.ac.cr

**Resumen**—Este documento consolida los hallazgos finales del desarrollo e implementación de un protocolo de evaluación para sistemas Text-to-Speech (TTS) y clonación de voz (Zero-Shot). Se sintetizan los resultados de la validación biométrica mediante ECAPA-TDNN, el análisis espectral con MCD y la evaluación perceptual humana contrastada con el modelo neuronal NISQA.

**Index Terms**—Clonación de Voz, Biometría, ECAPA-TDNN, NISQA, Similitud Coseno, Deepfakes, XTTS v2.

## I. INTRODUCCIÓN

El rápido avance de las tecnologías de síntesis Text-to-Speech (TTS) y conversión de voz ha facilitado el desarrollo de arquitecturas capaces de clonar identidades vocales a partir de muestras de audio sumamente cortas, un paradigma conocido como clonación *Zero-Shot*. Si bien modelos fundacionales de código abierto como XTTS v2 logran un alto grado de naturalidad en la voz sintética, la evaluación cuantitativa de qué tan fiel es la identidad generada respecto al hablante original sigue representando un desafío técnico. Históricamente, la similitud vocal y la calidad del habla se han medido casi exclusivamente mediante pruebas perceptuales humanas, como el *Mean Opinion Score* (MOS). Sin embargo, estas evaluaciones subjetivas son inherentemente costosas, consumen mucho tiempo y carecen de la estandarización necesaria para ser reproducidas con facilidad en distintos laboratorios.

Ante esta limitación, se vuelve necesaria la transición hacia marcos de evaluación automatizados y objetivos. Además, en un panorama donde la proliferación de audios generados por inteligencia artificial (*deepfakes*) supone riesgos de seguridad y suplantación de identidad, es crítico contar con herramientas biométricas capaces de distinguir de manera confiable entre señales de voz humanas genuinas y aquellas sintetizadas artificialmente.

Este proyecto tiene como objetivo principal diseñar e implementar un protocolo de evaluación de similitud de voz que sea de bajo costo, reproducible y éticamente fundamentado. Para lograrlo, el marco de trabajo propuesto integra el análisis de distorsión espectral mediante *Mel Cepstral Distortion* (MCD), la extracción de características biométricas profundas

(*d-vectors*) utilizando la arquitectura ECAPA-TDNN, y la predicción no intrusiva de la naturalidad del habla mediante el modelo de atención neuronal NISQA. Al contrastar estas métricas computacionales directas con los resultados empíricos de evaluaciones perceptuales humanas, este trabajo establece una base metodológica robusta para auditar, caracterizar y validar el desempeño de sistemas modernos de tecnologías del habla.

## II. RESUMEN TÉCNICO DE RESULTADOS

Esta sección consolida los hallazgos cuantitativos y cualitativos obtenidos tras procesar el banco de pruebas, compuesto por voces naturales de referencia y sus respectivos clones sintéticos generados mediante XTTS v2, a través del protocolo de evaluación automatizado.

### II-A. Validación Biométrica (ECAPA-TDNN)

La extracción de *d-vectors* mediante la arquitectura ECAPA-TDNN demostró ser un método altamente discriminativo para la verificación de locutores en contextos de síntesis. El análisis de la matriz de similitud del coseno permitió agrupar de manera exitosa las muestras genuinas, distanciándolas algorítmicamente de las muestras generadas artificialmente. Al trazar las curvas ROC y establecer un umbral de decisión óptimo, el sistema logró aislar los ataques de suplantación, arrojando una Tasa de Igualdad de Error (EER) que evidencia la robustez de las representaciones biométricas frente a la clonación *Zero-Shot*.

### II-B. Distorsión Espectral (MCD)

Para cuantificar la fidelidad acústica estructural, se calculó la Distorsión Mel Cepstral (MCD) alineando dinámicamente los espectrogramas de los audios de referencia con sus equivalentes clonados. Las distancias obtenidas indican que, si bien el modelo generativo captura satisfactoriamente las características formánticas base de la identidad, introduce artefactos y alteraciones en las dinámicas de alta frecuencia y en la variabilidad prosódica. Esta brecha espectral objetiva es consistente con la degradación acústica que penalizan los modelos de evaluación de calidad.

## II-C. Evaluación Perceptual (MOS vs. NISQA)

El protocolo contrastó de manera exitosa las métricas computacionales con pruebas perceptuales humanas estandarizadas bajo la escala *Mean Opinion Score* (MOS). Los resultados empíricos extraídos de los formularios de evaluación arrojaron una calificación promedio de 4.64/5.00 para la naturalidad de las voces humanas de referencia, marcando un claro contraste con el 2.61/5.00 obtenido por las muestras sintéticas. Asimismo, la prueba ABX diseñada para medir la preservación de la identidad vocal (similitud) alcanzó un promedio global de 2.99/5.00. La degradación reflejada en estos puntajes humanos correlacionó efectivamente con las predicciones no intrusivas generadas por la red neuronal NISQA, demostrando la viabilidad de utilizar esta arquitectura de *self-attention* para predecir la calidad del habla sintética sin depender de encuestas manuales continuas.

## III. CONCLUSIONES

- **Efectividad del Protocolo:** Se demostró que la combinación de métricas objetivas (*d-vectors*) y redes predictivas (NISQA) permite evaluar sistemas TTS de forma altamente automatizada, reduciendo la dependencia de costosas pruebas humanas (MOS tradicionales).
- **Rendimiento Zero-Shot:** El modelo XTTS v2 demostró una capacidad sobresaliente para capturar el timbre general con pocos segundos de referencia, aunque métricas como el MCD revelaron deficiencias en las dinámicas de alta frecuencia y prosodia fina.
- **Detección de Deepfakes:** El umbral calculado en las Curvas ROC establece una base sólida para distinguir entre una identidad humana genuina y un ataque de suplantación sintética.

## IV. APLICACIONES Y TRABAJO FUTURO

El marco de evaluación desarrollado en este proyecto sienta las bases para diversas líneas de investigación y expansión técnica:

- **Diversidad Dialectal:** Expansión del banco de datos (*dataset*) del laboratorio para abarcar una mayor variedad fonética y dialectal del español costarricense, estructurándolo de manera más ordenada y representativa.
- **Donación de Voz y Tecnologías de Asistencia:** Implementación del protocolo y sus métricas de similitud para asignar, de manera óptima y personalizada, voces sintéticas a personas con dificultades severas en el habla.
- **Detección de Deepfakes en Tiempo Real:** Desarrollo de un módulo de seguridad automatizado capaz de operar en tiempo real sobre distintos canales de comunicación, con el objetivo de identificar y alertar sobre la presencia de audios sintéticos o ataques de suplantación.
- **Optimización en Hardware:** Migración del procesamiento y análisis de las señales de audio hacia infraestructuras o arquitecturas de hardware dedicadas, facilitando la materialización del protocolo en una herramienta física más accesible y eficiente.

- **Desarrollo de Nuevas Métricas Objetivas:** Diseño de algoritmos avanzados que logren capturar características sonoras sutiles del lenguaje que el oído humano suele omitir, permitiendo, por ejemplo, diferenciar computacionalmente a un imitador humano del locutor original.

## V. CONSIDERACIONES ÉTICAS

El desarrollo y evaluación de tecnologías de síntesis y clonación de voz operan dentro del espectro de las tecnologías de doble uso. Si bien presentan beneficios significativos para las aplicaciones de asistencia y la donación de voz, también introducen riesgos sustanciales relacionados con la suplantación de identidad, el fraude y la desinformación. Por lo tanto, el diseño de este protocolo de evaluación se rigió bajo estrictos lineamientos éticos:

- **Consentimiento Informado y Privacidad:** Todas las muestras de voz humana utilizadas para conformar el banco de pruebas fueron recopiladas con el consentimiento explícito de los participantes. Las representaciones acústicas y los *d-vectors* biométricos extraídos se manejan como datos sensibles, restringiendo su uso exclusivamente a fines de investigación académica dentro de la Universidad de Costa Rica.
- **Transparencia y Divulgación:** En cumplimiento con las directrices de ética en inteligencia artificial, todos los audios generados mediante la arquitectura XTTS v2 fueron estrictamente etiquetados y aislados como material sintético. Se establece como principio que cualquier implementación en el mundo real derivada de esta tecnología debe informar de manera transparente a los usuarios cuando estén interactuando con voces generadas artificialmente.
- **Enfoque Defensivo:** El propósito central de establecer métricas de similitud, como la distancia del coseno y la evaluación NISQA, no es perfeccionar la capacidad de engaño de los modelos generativos, sino dotar a la comunidad de ingeniería con herramientas computacionales auditables. Esto permite establecer líneas base robustas para la detección de ataques y salvaguardar la integridad biométrica de los usuarios.

## REFERENCIAS

- [1] Coqui AI, "XTTS: A massively multilingual zero-shot text-to-speech model," 2023.
- [2] F. Desplanques, J. Thienpondt, and K. Demuynck, "ECAPA-TDNN: Emphasized Channel Attention, Propagation and Aggregation in TDNN Based Speaker Verification," Interspeech, 2020.
- [3] G. Mittag, B. Naderi, A. Chehadi, and S. Möller, "NISQA: A Deep CNN-Self-Attention Model for Multidimensional Speech Quality Prediction with Crowdsourced Datasets," Interspeech, 2021.