

# Informe Técnico de Análisis Comparativo: Evaluación Objetiva y Subjetiva de Similitud Vocal

Daniel Valverde Ortiz  
Escuela de Ingeniería Eléctrica  
Universidad de Costa Rica  
San José, Costa Rica  
daniel.valverdeortiz@ucr.ac.cr

Marvin Coto Jiménez  
Departamento de Automática  
Escuela de Ingeniería Eléctrica, UCR  
San José, Costa Rica  
marvin.coto@ucr.ac.cr

**Resumen**—Este informe detalla el contraste empírico entre las métricas objetivas computacionales y la percepción auditiva humana, evaluada mediante pruebas perceptuales tipo MOS y ABX. Se aplicaron los instrumentos de evaluación sobre un banco piloto de audios en español costarricense, contrastando los juicios de 25 evaluadores voluntarios frente a los resultados biométricos extraídos por la arquitectura profunda ECAPA-TDNN y las estimaciones neuronales del modelo no intrusivo NISQA. Los resultados demuestran una discrepancia significativa entre la calidad proyectada por los algoritmos y la severidad del oído humano frente a artefactos de clonación, estableciendo una línea base fundamental para el desarrollo de tecnologías TTS en el contexto local.

**Index Terms**—Evaluación perceptual, MOS, ABX, similitud de voz, Text-to-Speech, métricas objetivas, español costarricense.

## I. INTRODUCCIÓN Y RESUMEN EJECUTIVO

El presente documento consolida la fase de evaluación del protocolo reproducible diseñado para sistemas *Text-to-Speech* (TTS) y de conversión de voz dentro del marco del laboratorio LAPA-CR. El núcleo de este análisis consiste en validar la correlación entre las distancias acústicas calculadas matemáticamente (Similitud Coseno, *Mel Cepstral Distortion*) y el nivel real de engaño o aceptación por parte del oído humano frente a estímulos sintéticos.

Dichos estímulos fueron generados mediante inferencia *zero-shot* con el modelo fundacional XTTS v2, el cual permite la clonación de identidad utilizando audios de referencia de corta duración. Este informe busca responder si las métricas objetivas actuales son suficientes para predecir la confiabilidad de una voz clonada sin intervención humana.

## II. RESULTADOS CUANTITATIVOS COMPUTACIONALES

### II-A. Análisis Acústico y Biométrico

El procesamiento automatizado para la distinción de identidades mediante *Speaker Embeddings* extraídos por el clasificador ECAPA-TDNN demostró una precisión biométrica inicial robusta en la separación de locutores genuinos y clones sintéticos.

- **Precisión del Sistema:** Se determinó un *Equal Error Rate* (EER) del 8,33 %. Este valor indica que el protocolo tiene un margen de error bajo al clasificar falsos positivos y falsos negativos, demostrando viabilidad para auditorías de suplantación.

- **Frontera de Decisión:** El umbral matemático óptimo (Threshold) quedó fijado algorítmicamente en 0,6941. Cualquier cruce vectorial por encima de este valor es clasificado como la misma identidad.
- **Distorsión Espectral:** La desviación promedio entre audios reales y clones, medida mediante *Mel Cepstral Distortion* (MCD), fue de 514,35 dB. Cabe destacar que la magnitud absoluta difiere del estándar teórico debido a la base del logaritmo natural nativa de la librería Librosa, pero mantiene su validez como distancia relativa.




Figura 1. Matriz de similitud coseno entre audios reales y sintéticos.

Como se observa en la Figura 1, la matriz de similitud evidencia las agrupaciones de identidad y los cruces entre las voces de referencia y sus respectivos clones.

### II-B. Estimación No Intrusiva (NISQA)

El modelo de evaluación computacional NISQA, que opera de forma autónoma analizando espectrogramas mediante redes convolucionales sin requerir una señal de referencia alineada, predijo una naturalidad sumamente alta para ambas clases de pistas de audio:

- **Voz Natural:** Predicción MOS computacional de 3,93/5,00.
- **Voz Sintética (Clon):** Predicción MOS computacional de 3,75/5,00.

Estas cifras proyectaban que los audios sintéticos serían percibidos con una calidad muy cercana a la de un hablante real.

### III. RESULTADOS DE LA EVALUACIÓN PERCEPTUAL HUMANA

Para el contraste empírico, se diseñó y aplicó un instrumento de evaluación en línea mediante Google Forms a  $N = 25$  participantes voluntarios. El banco de pruebas se segmentó ocultando la naturaleza de las muestras para evitar sesgos: audios naturales (Muestras 1, 4, 6 y 7) y audios generados sintéticamente (Muestras 2, 3, 5 y 8).

#### III-A. Prueba MOS (Calidad y Naturalidad)

Los evaluadores humanos determinaron una separación de calidad drástica que los algoritmos no lograron pronosticar con la misma magnitud:

- Las muestras originales recibieron una puntuación MOS promedio de **4,64/5,00** ( $\sigma = 0,67$ ), confirmando una claridad e inteligibilidad humana indiscutible.
- Las muestras sintéticas experimentaron una caída severa, obteniendo un MOS promedio de **2,61/5,00** ( $\sigma = 1,06$ ).




Figura 2. Distribución de las calificaciones MOS de naturalidad ( $N = 25$ ) contrastando el desempeño de las muestras originales frente a los clones sintéticos.

La dispersión de estas calificaciones ilustrada en la Figura 2, evidencia que pese a la estabilidad de los formantes básicos en las bajas frecuencias, los oídos humanos penalizan de forma drástica cualquier artefacto robótico residual, cortes abruptos o irregularidades de prosodia presentes en la clonación de XTTS v2.

#### III-B. Prueba ABX (Similitud de Identidad)

Frente a la consigna de evaluar exclusivamente qué tan parecida era la identidad de la voz sintetizada con respecto a la fuente original, el puntaje humano promedió **2,99/5,00**. Este valor corrobora estadísticamente una similitud "moderada", coincidiendo estrechamente con el comportamiento registrado en las matrices de calor del clasificador biométrico, donde los cruces de clon contra audio real se posicionaron muy cerca de la frontera de aceptación, fallando en replicar la identidad perfecta pero logrando un nivel de engaño considerable.

### IV. ANÁLISIS DE CORRELACIÓN Y DISCUSIÓN

La investigación evidenció una brecha significativa entre la calificación proyectada por la Inteligencia Artificial (NISQA) y la opinión de los usuarios reales. Mientras que el modelo neuronal otorgó a las voces sintéticas un valor cercano a 3,75

(buena calidad comercial), los humanos puntuaron un 2,61 (calidad regular/deficiente).




Figura 3. Comparativa espectral entre la voz natural (referencia) y la voz sintetizada. Se aprecia la atenuación de energía acústica en las bandas frecuenciales superiores.

Como se ve en la Figura 3, esta sobreestimación algorítmica sugiere fuertemente que el modelo fundacional sufre una pérdida frecuencial apreciable en las bandas superiores a los 4096 Hz. Estas atenuaciones de alta frecuencia no afectan dramáticamente las distancias matemáticas euclidianas del MCD ni los cálculos de la IA, pero sí fracturan la naturalidad percibida por el complejo sistema auditivo humano.

### V. LIMITACIONES METODOLÓGICAS

El protocolo experimental presentó ciertas restricciones que deben considerarse para trabajos futuros:

- **Ruido en la Ingesta de Datos:** La recolección de las voces de referencia en ambientes no controlados introdujo reverberación de sala y ruido de fondo, lo cual indujo micro-silencios y asimetrías que afectaron levemente la alineación DTW en el cálculo de los coeficientes MFCC base.
- **Volumen Poblacional del Dataset:** La evaluación subjetiva se estructuró sobre 4 identidades distintas. Esto limita la exposición del sistema a un rango de variación fonética y dialectal más extenso propio del español costarricense.
- **Restricciones de Hardware y Cómputo:** El procesamiento local de inferencia *zero-shot* y la extracción de *embeddings* profundos demandaron el uso de aceleración gráfica dedicada. Si bien esto garantizó tiempos estables para este dataset piloto, representa un cuello de botella logístico si se desea escalar el protocolo a bases de datos masivas.